

서찬진 · ChanJin Seo

Email scj1507@gmail.com

GitHub github.com/seochanjin

AI Backend · AI Platform Engineer

AI 기능을 상태·실패·배포·관측성까지 연결해 운영 가능한 서비스로 구현합니다.

01

AI Pipeline & Backend

RAG · Embedding · Async Processing · State Management ·
Failure Handling

02

Platform & Operations

Docker · K3s · GitHub Actions · Prometheus · Grafana ·
Troubleshooting

03

AX & Automation

Workflow Design · Human Approval · Agent-assisted
Development

AI 서비스 설계·구현

3-Node Hybrid K3s 운영

로그·지표 기반 검증과 개선

프로젝트 요약 및 목차

문제 정의부터 설계·구현·운영·회고까지 이어진 3개의 프로젝트를 정리했습니다.

01 NewsLab

2026.05–2026.07 · 이후 운영/유지보수 · 개인 Project

한 줄 설명

여러 뉴스 기사를 Topic 단위로 묶고 요약해 제공하는 장기 운영 AI 뉴스 플랫폼

본인 역할

AI Pipeline · Backend API · K3s Operations Monitoring · Troubleshooting

대표 성과

• RSS 10개 Source에서 기사 6,300여 건 수집

• 고비용 원문 추출 범위를 전체 기사의 7.4%로 제한

• Redis cache-aside 적용으로 100 VU p50 1.22초 → 26.05ms

FastAPI · PostgreSQL/pgvector · Next.js · Docker · K3s · GitHub Actions · Prometheus/Grafana

AI Backend

K3s 운영

관측성

상세 페이지

03–10

운영 지표 기준: 2026.07

02 NotebookLM Clone

2026.03–2026.04 · 개인 Project

한 줄 설명

PDF 분석부터 Hybrid RAG 답변과 근거 저장까지 구현한 문서 기반 AI 서비스

본인 역할

Spring Boot–FastAPI 책임 분리 문서 상태 · Reference · AiCallLog · RAG Pipeline 설계

대표 성과

• PROCESSING · COMPLETED · FAILED 기반 문서 상태 관리

• pgvector MMR · Keyword Search · Local Reranker 결합

• Quota 최종 실패 시 Partial Vector Cleanup 적용

Spring Boot · FastAPI · PostgreSQL/pgvector · Redis · Gemini API · Docker Compose · Nginx

RAG

처리 상태 관리

실패 복구

상세 페이지

11–16

03 ACCIO

2025.10–2025.11 · 5인 Team Project

한 줄 설명

자연어 상품 검색과 대화형 탐색 경험을 구현한 AI 쇼핑 서비스

본인 역할

Elasticsearch 검색 랭킹 · Frontend State Management · Guest Cart 병합 · 인증 흐름 개선

대표 성과

• 화면 이동·새로고침 이후 AI 대화와 검색 결과 복원

• 병합 실패 격리로 로그인 흐름 보호

• 비회원 Cart와 로그인 사용자 Cart 병합

React · TypeScript · FastAPI · Elasticsearch · MongoDB · Redis · AWS Bedrock

AI UX

상태 복원

세션 관리

상세 페이지

17–20

여러 기사를 하나의 뉴스 흐름으로 재구성하는 AI 플랫폼

기간	형태	Live Service	GitHub
2026.05-2026.07 이후 운영/유지보수	개인 프로젝트 실제 운영	https://newslab.ai.kr	backend frontend

기획 배경

K3s를 단순 설치 실습으로 끝내지 않고, 정기적인 데이터 수집·Batch 처리·API·Web 배포와 장애 대응을 반복해서 경험할 수 있는 장기 프로젝트

문제 정의

RSS 기사 목록만으로는 여러 매체가 반복 보도하는 같은 사건을 구분하기 어렵고, 하루의 주요 뉴스 흐름을 빠르게 파악하기 어려움

핵심 가설

제목과 RSS 요약을 Embedding해 의미적으로 유사한 기사를 묶고, 반복 보도량을 주목도 신호로 활용하면 기사를 Topic 단위 뉴스 흐름으로 재구성할 수 있다고 판단

목표


선정된 기사에만 원문 추출과 LLM 요약을 수행해 비용과 실패 범위를 제한하면서 Daily·3일·주간 뉴스 흐름을 제공

기술 스택

Platform	Docker · K3s · Traefik · Argo CD · GitHub Actions · Prometheus/Grafana · Alertmanager
Backend/Data	Python · FastAPI · PostgreSQL/pgvector
Frontend	Next.js · TypeScript



홈 화면 · 주요 이슈 · 최근 흐름




상세 페이지 · 핵심 포인트 · 키워드

토픽 페이지 · 관련 기사 모음

Hybrid K3s 위에서 운영하는 End-to-End 구조

Oracle Cloud A1 노드 2대와 Raspberry Pi Worker 1대를 Tailscale 기준으로 통합 운영



핵심 설계 결정

노드 배치 판단

- master — control plane + 클러스터 add-on
 - worker — 앱 전용 (workload=app)
 - Pi — NoSchedule, 관측만
- 가정 회선·전원 의존 → 전달 보장 워크로드 제외
- worker memory request 12% → 확장 불필요

운영 경계

- 조회·진단 — Agent 보조
- Git 관리 대상 — Argo CD manual sync, 사람 승인
- Secret-monitoring-rollout — 사람이 직접

모든 기사에 고비용 처리를 하지 않는 단계형 AI Pipeline


문제

- 모든 기사 원문을 선추출하면 외부 요청 수와 실패 지점이 기사 수에 비례해 증가
- Daily·3-day·Weekly 실행마다 Embedding을 다시 만들면 동일 기사에 비용과 처리시간이 반복 발생
- 기사 단위 오류를 격리하지 않으면 일부 실패 때문에 해당 실행 전체 결과가 영향받을 수 있음

설계 결정

- 제목·RSS 요약·매체·분류 정보를 결합해 기사당 1개 Embedding을 생성하고 Source Hash로 재사용
- 운영 기사 샘플에서 Cosine Similarity Threshold 0.60~0.80을 비교해 운영값 0.70 선택
- 시간 범위별 기사량에 따라 Summary 근거 수를 차등 적용 Daily·3-day 최대 3건 · Weekly 최대 5건
- Stage별 실패 격리로 부분 실패가 전체 Batch로 번지지 않게 설계

Stage 분리 — 전체 기사에서 근거까지, 실패 격리 단위



수집 6,372건 → Embedding 4,042건 → 원문 추출 469건(7.4%) → Summary 232회

운영 지표 기준: 2026.07.19

Daily CronJob 산출물을 3-day · Weekly가 재사용

Daily CronJob · 04:00

매일 실행

기사 메타데이터 Embedding (DB 저장) → Selection → Extraction → Summary

Daily Summary 근거 최대 3건

3-day·Weekly는 기존 Embedding을 재사용하고 Selection · Extraction · Summary 단계만 다시 실행합니다.

3-day

매일 실행

최근 72시간 기사를 기존 Embedding으로 재클러스터링 3-day 전용 테이블과 API에 저장 Summary 근거 최대 3건

Weekly

주 1회 실행

직전 완료 주간 기사를 기존 Embedding으로 재클러스터링 Weekly 전용 테이블과 API에 저장 Summary 근거 최대 5건

NewsLab 운영 장애 진단 및 대응

Networking · Batch · Memory 세 가지 사례의 증상, 판단, 조치, 검증을 정리

Networking

Ready인데 kubectl logs 실패

상황

유휴 Raspberry Pi를 K3s Worker로 추가해 Cloud와 Home Lab을 결합한 Hybrid Cluster 구성

문제

OCI Private Network와 가정 LAN의 경계가 다르고 Node가 Private·LAN·Tailscale 주소를 혼용

판단·조치

소규모 3-Node 환경에서 설정이 단순한 Tailscale을 선택하고 node-ip / flannel-iface를 Tailscale 주소로 통일

검증

양쪽 Worker 로그 확인 Pi에 NoSchedule Taint 적용

Evidence: docs/devlog/infra-pi-worker-join.md

Batch

Daily Pipeline 5시간 이상 Running

상황

Daily Pipeline이 5시간 이상 Running 상태로 남음

한계

재실행에서는 정상 완료되어 동일 현상을 재현하지 못했고 확정 원인은 특정하지 못함

조치

concurrencyPolicy: Forbid activeDeadlineSeconds: 1800 backoffLimit: 1 Stage Progress Log 추가

효과

중복 실행과 장시간 실행의 상한을 설정하고 재발 시 정체 Stage를 확인할 진단 경로 확보

Evidence: k8s/news-daily-topic-pipeline-cronjob.yaml

Memory


Grafana OOMKilled · Exit 137

배경

제한된 Worker 자원에서 Monitoring Core를 운영하고 Prometheus 데이터 보관 기간을 1일로 제한

판단·조치

Container Memory Limit 초과로 판단



검증

3/3 Running · Restart 0

Evidence: k8s/monitoring/kube-prometheus-stack-values.yaml

AI Agent 개발 작업의 승인·검증 경계 설계

Agent의 구현과 Production 반영 사이에 Review · Human Approval · Verification 경계 설정

AI AGENT DEVELOPMENT HARNESS

01 Human Define

요구사항 · 완료 기준 · 금지 영역 정의



02 Agent Work

승인된 범위에서 구현 코드 · 테스트 · 문서 수정



03 Review & Human Approval

Antigravity · CodeRabbit 독립 Review 사람이 수정 범위를 승인

Review Issue → Human Approval → Agent Rework → Verification



04 Verification → Human Production

허용된 테스트와 기존 계약 검증 Merge · DB Migration · K3s 반영은 사람이 수행

01 시작 계기

- AI를 검색·코드 보조 도구로만 사용
- 단순 질의가 아닌 반복 가능한 개발 Workflow로 구성 필요

02 적용 방향

- Harness Engineering 개념 참고 — 권한·검증·상태 관리
- Agent 작업 범위 / 독립 Review / 사람 승인 / Production 변경 권한 분리
- Review 결과 자동 반영 없음 — 승인 항목만 Agent가 재수정

03 실제 적용

- Daily Topic Pipeline을 1개 진입점 → 4개 Stage 분리 Embedding · Topic Selection · Raw Acquisition · Summary·Save
- Review 중 발견 — Stage별 날짜 개별 계산 시 UTC/KST 경계에서 pipeline_date 불일치 가능
- 공통 PipelineContext 도입 → 전 Stage 동일 날짜 전달
- 날짜 경계 테스트 포함 150개 통과, API·DB Schema 및 금지 영역 변경 0건

04 배운 점과 한계

- 많이 말기는 것보다 어느 지점에서 사람이 판단할지 정의가 중요
- 한계 — 작업 상태가 여러 문서에 분산, 새 세션이 현재 상태 파악 어려움
- 다음 — 단일 PROGRESS.md와 기계 가독 Feature 상태로 Session Lifecycle 보완

Agent — 구현 · 테스트 · 문서 · 검증 자료 작성

Human — 요구사항 확정 · 수정 범위 승인 · Merge · DB/K3s/Secret 변경 · 운영 검증

반복 조회 부하를 캐시 계층으로 분리한 Home API

100 VU에서 확인한 포화 지점을 cache-aside로 완화하고 before/after를 동일 조건으로 측정

p50 (100 VU)

1.22s → **26.05ms**

RPS 증가율 (50→100 VU)

39% → **97%**

단계별 측정 (Before → After)			
VU	RPS	p50	p95
1	0.63 → 0.94	533ms → 19ms	765ms → 36ms
10	6.15 → 8.82	516ms → 18ms	685ms → 33ms
25	13.87 → 20.68	520ms → 20ms	1.51s → 93ms
50	29.07 → 43.88	517ms → 22ms	1.35s → 266ms
100	40.50 → 86.59	1.22s → 26ms	2.20s → 412ms

cache-aside 흐름

요청 → Redis 조회

└ hit → 응답

└ miss → PostgreSQL 조합 → Redis 저장 시도 → 응답

저장 실패·timeout 50ms 초과에도 응답은 계속 (fail-open)

k6 fixed-VU 30s · 각 단계 cold-cache 시작 · 측정 endpoint는 동일 Ingress의 대체 호스트 api.dev-scj.site

01 배경

- Home API — Daily·3-day·Weekly Topic을 매 요청마다 PostgreSQL에서 조합
- Topic은 CronJob 실행 시점에만 갱신, 조회는 훨씬 빈번

02 문제

- 1~50 VU 구간 p50 516~533ms로 평탄
- 100 VU에서 p50 1.22초 · p95 2.20초 · p99 3.25초로 급증
- 50→100 VU RPS 증가율 약 39% — 포화 징후로 판단

03 설계 판단

- PostgreSQL은 source of truth 유지, Redis는 삭제 가능한 캐시 계층으로 한정
- fail-open — 미설정·연결 실패·timeout·payload 손상 전부 PostgreSQL fallback
- 최신성은 TTL이 아닌 prewarm — Pipeline 저장 직후 동일 builder로 key overwrite

04 실제 적용과 결과

- 100 VU — p50 1.22초 → 26.05ms, RPS 40.50 → 86.59
- 50→100 VU RPS 증가율 39% → 97%, 해당 구간 포화 완화
- p99는 3.25초 → 2.25초로 개선폭 상대적으로 작음
- 전 단계 HTTP 오류 0건 · Pod restart 0건

05 한계와 다음 검증

- 각 단계 cold-cache 시작 → 10·50 VU p99가 Before보다 높음
- 요청별 trace·DB 지표 없어 원인 미확정
- 30초 단발 측정 — 장시간 부하 hit rate 추이 미확인

캐시가 죽어도 API가 죽지 않는 구조를 실제로 확인

Production Redis를 중단하고 PostgreSQL fallback과 복구 후 재생성을 순서대로 검증

중단 → 복구 검증 순서

① 정상 Redis 1/1 EXISTS=1	② Redis 중단 replicas=0 · Pod 없음 HTTP 200 · 846ms items 10 · restart 0 fail-open 확인	③ 복구 replicas=1 · EXISTS=0 miss → store → hit 49ms
---	---	--

fallback 경로

요청 → Redis 조회 timeout 50ms
└ hit → 응답
└ miss → PostgreSQL → 저장 시도 → 응답
└ 오류·timeout → PostgreSQL → 응답
캐시 실패가 요청 실패로 이어지지 않습니다

단위 테스트로 검증한 실패 경로

GET timeout	SET 실패
connection 오류	손상된 payload
malformed URL	unsupported scheme
TTL 만료	Redis 미설정

회귀 테스트 422 passed · Argo CD Synced/Healthy · restart 0 · 검증 시점 TTL 60초
(현재 운영값 Daily·3-day 108,000초 / Weekly 691,200초)

Redis 중단·복구는 사람이 승인해 직접 실행했으며 Agent는 production mutation을 실행 x

01 배경

- Redis 도입 → Home API가 캐시 계층에 의존
- "캐시 없어도 응답한다"는 코드에만 있던 전제 — 중단시켜 보기 전까지는 가정

02 문제

- Redis 장애 형태 다양 — 연결 실패 · timeout · payload 손상 · URL 설정 오류
- 각 경우가 예외로 전파되면 캐시가 오히려 장애 지점을 늘림

03 설계 판단

- fail-open — 모든 Redis 오류를 PostgreSQL fallback으로 격리
- connect·read timeout 50ms — 캐시 지연이 응답 지연으로 전이되지 않게 제한
- persistence 없이 운영 — 유실 시 PostgreSQL에서 재생성
- 단위 테스트로 실패 경로 8종 개별 검증

04 실제 적용과 결과

- 사람이 승인한 운영 창에서 replicas=0으로 Redis 중단
- Redis Pod 부재 상태에서 /topics/home — HTTP 200 · 기존 schema 유지 · items 10건
- API Pod restart 0건
- 복구 후 EXISTS=0 → miss → store(TTL 60) → hit(49ms) 순서대로 확인

05 한계와 다음 검증

- 운영 로그에 home_topics_cache event 미노출 → hit·miss·store를 key 존재와 TTL 변화로 확인
- PostgreSQL query·connection 수 미수집 → DB 부하 감소량 정량화 안 함
- cold-cache 동시 요청의 cache stampede 대응 없음

NewsLab / 운영 리뷰와 성장 방향

01 전 프로젝트 대비 개선점

1. 서비스 범위 확장

NotebookLM Clone이 문서 기반 AI 서비스 구현에 집중했다면, NewsLab은 수집·AI 처리·API·Web·배포·모니터링까지 실제 운영 범위로 확장했습니다.

2. 실행 환경 확장

Docker Compose 중심 환경에서 Oracle Cloud와 Raspberry Pi를 연결한 3-Node Hybrid K3s로 확장했습니다.

3. 처리 방식 확장

요청 단위 처리에서 Daily·3-day·Weekly CronJob 기반 Batch Pipeline으로 확장하고, Embedding 재사용과 선택 원문 추출을 적용했습니다.

4. 운영 신뢰성 확장

기능 배포에서 멈추지 않고, 승인형 GitOps 배포 통제, 운영 Dashboard·Alerting, 캐시 계층의 fail-open 검증, DB Backup·격리 Restore 훈련까지 운영 신뢰성 범위를 확장했습니다.

기능 구현 중심 프로젝트에서 배포·관측·알림·복구까지 다루는 운영 프로젝트로 확장했습니다.

02 운영하며 얻은 인사이트

1. 쿠버네티스 운영

Manifest 작성보다 Control Plane, Node, Pod, Network 경로를 나눠 장애 범위를 좁히는 능력이 더 중요했습니다.

2. AI 파이프라인

Model과 Prompt뿐 아니라 처리 상태, 부분 실패, 재실행, 날짜 경계, 저장 정합성까지 함께 설계해야 했습니다.

3. 에이전트 작업 흐름

작업을 많이 맡기는 것보다 수정 범위, 검증 기준, 운영 권한을 어디서 사람이 통제할지 정하는 것이 중요했습니다.

4. 관측과 복구

Dashboard로 상태를 보는 것과 이상 상태가 운영자에게 전달되는 것은 다른 문제였고, Backup 파일의 존재와 실제 복구 가능성도 다른 문제였습니다. 전달과 복구는 검증하기 전까지 가정일 뿐이었습니다.

운영은 기능이 동작하는지 확인하는 일이 아니라, 실패 범위와 복구 경로를 설계하는 일이었습니다.

03 완료한 개선과 남은 한계

완료한 개선

1. 운영 Dashboard와 Alerting

Pipeline 운영 Dashboard와 Alert 3종을 구성하고 Telegram 전달을 end-to-end 검증했습니다.

2. 캐시 계층과 장애 검증

Home API에 Redis cache-aside를 적용하고 Production Redis 중단으로 fallback을 확인했습니다.

3. Backup/Restore 검증

논리 Backup을 격리 환경에 Restore해 정합성을 확인하고 절차를 Runbook으로 남겼습니다.

남은 한계와 다음 개선

1. 장기 Metric 보관과 SLO

현재: Prometheus retention 1일로 장기 성공률·추세 측정이 불가능합니다.

다음: 장기 저장 구조를 마련한 뒤 Pipeline 성공률·완료 시각을 SLI로 정의하고 SLO를 검토합니다.

2. Backup 자동화와 RPO/RTO

현재: 수동 훈련으로 특정 시점의 복구 가능성은 검증했지만, 정기 실행과 보존 정책은 없습니다.

다음: Backup 자동화·보존 정책을 구성하고 반복 훈련으로 RPO/RTO를 측정합니다.

3. 운영 파라미터 재검증

현재: Cosine Similarity 0.70, Daily·3-day 최대 3건, Weekly 최대 5건을 사용합니다.

다음: 소스 수와 Topic 크기가 증가하면 임계값과 근거 수를 재검증합니다.

04 다음 성장 방향

1. 연결된 시각

NewsLab을 통해 AI 백엔드, 플랫폼, 업무 자동화가 하나의 서비스 안에서 연결된다는 점을 확인했습니다.

2. AI 백엔드

AI 기능 자체보다 처리 상태, 실패 계약, 도구 실행, 권한과 감사 가능성까지 함께 설계하고 싶습니다.

3. 플랫폼 운영

승인형 GitOps와 이미지 rollback, 운영 Alerting, 데이터 Restore 검증을 바탕으로, 장기 Metric 보관과 SLI·SLO 설계로 운영 신뢰성 검증 범위를 확장하고 싶습니다.

4. 개발 방식의 균형

Agent는 반복 작업과 Review에 활용하고, 핵심 로직은 직접 설계·구현해 생산성과 코드 이해도를 함께 확보하겠습니다.

AI 기능을 데이터 흐름·운영 환경·권한 경계까지 연결하는 AI 백엔드 / 플랫폼 엔지니어로 성장하고자 합니다.

문서 근거와 처리 상태를 관리하는 RAG 서비스

PDF 업로드, 비동기 분석, Hybrid RAG 검색, 답변 근거 저장을 하나의 서비스 흐름으로 구현

기간	형태	GitHub
2026.03-2026.04	개인 프로젝트	https://github.com/notebooklm-clone-sci
	4개 Repository 분리 구성	
	배포검증 NCP ·	

기획 배경

팀 프로젝트에서 경험한 RAG를 직접 설계·구현하며, Java·Spring 기반 서비스 관리와 Python·FastAPI 기반 AI 처리 구조를 학습하기 위해 시작

문제 정의

PDF 분석은 처리 시간이 길어 외부 API 실패 시 문서 상태와 Vector 데이터가 어긋날 수 있음
답변 근거 미저장 시 어떤 문서를 기반으로 답변했는지 사후 확인 불가

설계 방향

Spring Boot는 사용자·문서·채팅·처리 상태를 관리

FastAPI는 PDF 파싱·Embedding·검색·LLM 호출을 담당

문서 분석은 비동기 실행하고 결과를 PROCESSING · COMPLETED · FAILED 상태로 관리


핵심 구현

Hybrid RAG 검색, 답변 Reference 저장, AI 호출 로그를 연결

문서 업로드부터 분석·검색·답변·근거 재조회까지 하나의 서비스 흐름으로 구현

기술 스택


Backend	Java · Spring Boot · Python · FastAPI
AI / Data	Gemini API · PostgreSQL/pgvector · Redis · LangChain
Frontend	Next.js · TypeScript
Infrastructure	Docker Compose · Nginx · NCP



운영 화면 · requestId 기반 AiCallLog 조회

NCP 단일 VM에 Docker Compose로 배포한 Runtime 구조

4개 Repository의 애플리케이션과 운영 설정을 Nginx 진입점 아래 하나의 실행 환경으로 조립




Repository → Runtime Component Mapping

core-api-spring Spring Boot · Domain / API	ai-worker-fastapi PDF · Embedding · Retrieval · LLM	frontend-ui Next.js · Chat / Reference UI	infra-config Docker Compose · Nginx · Environment
---	--	--	--

도메인 상태와 AI 처리를 분리한 비동기 문서 분석 구조

Spring Boot는 서비스 상태와 계약을 관리하고, FastAPI는 문서 분석과 AI 처리를 담당하도록 분리



01 배경

- PDF 파싱과 Embedding은 처리 시간이 길어, 분석이 끝날 때까지 업로드 요청을 유지하면 사용자 응답과 장시간 AI 처리가 결합되는 문제 발생

02 문제

- 외부 AI API 대기 중 요청 Thread·DB Transaction 장시간 유지 → 응답 지연과 Connection 점유 확대
- 처리 실패를 상태로 남기지 않으면 사용자가 분석 결과를 재확인 불가

03 설계 판단

- Spring Boot는 사용자 소유권, Document 상태, API 계약과 결과 저장을 담당
- FastAPI는 PDF 파싱, Summary, Chunking, Embedding과 Vector 저장을 담당하도록 책임을 분리
- 외부 AI API 대기 구간은 장시간 DB Transaction과 분리하고, 분석 결과를 저장할 때 필요한 DB 작업만 수행

04 실제 적용과 결과


- @Async + 전용 ThreadPoolTaskExecutor — Document를 PROCESSING으로 저장 후 documentId 즉시 반환
- 별도 Worker Thread가 FastAPI 호출 — 성공 시 COMPLETED, 실패 시 FAILED + errorMessage 저장
- 업로드 직후 처리 상태 조회 가능
- 사용자 응답 시간과 AI 처리 시간 분리
- 실패 상태를 Document 데이터로 추적

05 트레이드오프와 다음 개선

- Thread Pool Core 5 · Max 10 · Queue 50 — 부하 시험으로 도출한 최적값이 아닌 초기 설정
- 동시 업로드 증가 시 실행 지표 기반으로 Pool 크기 조정 예정
- 작업 Queue와 독립 Worker 도입 → API 요청과 문서 처리 Lifecycle 분리

Hybrid Retrieval과 답변 근거 저장 구조

pgvector MMR과 키워드 검색을 결합하고, 선택된 문서 근거를 답변과 함께 저장



01 배경

- Vector 유사도 검색은 의미가 비슷한 문서 탐색에 유용
- 인물명·날짜·숫자 같은 정확한 문자열 조건은 놓칠 수 있음

02 문제

- 유사도 결과만 사용 시 비슷한 Chunk 반복, 질문과 직접 관련된 문장보다 주변 문맥이 우선될 수 있음
- 답변만 저장하면 새로고침 이후 근거 문서 확인 불가

03 설계 판단

- Notebook·Document로 검색 범위 먼저 제한
- pgvector MMR 후보 + PostgreSQL ILIKE 후보 병합
- 중복 Chunk 제거 후 규칙 기반 재정렬 — 질문 토큰 중복도 · 직접 포함 여부 · 기존 MMR 순위 조합

04 실제 적용과 결과


- 선택된 Chunk를 답변과 함께 ChatReference로 저장
- 문서 제목 · Section · Page · Chunk 순서 · 원문 보존
- 새로고침 이후에도 동일한 답변 근거 재조회 가능

05 한계와 다음 개선

- 재정렬이 고정 규칙 기반, 정답 데이터셋 기반 검색 품질 평가 미수행
- 평가 질문·정답 근거를 구성해 Recall·MRR 측정 예정
- 필요 시 학습형 Reranker와 비교

Quota 실패 시 부분 저장을 정리하고 호출 원인을 추적한 구조

Embedding 배치 처리, 최종 실패 시 부분 Vector 정리와 실패 상태·호출 로그 기록



NotebookLM Clone / 설계 리뷰와 다음 검증

01 전 프로젝트 대비 개선한 점

- 1. 책임 분리
Spring Boot는 도메인 상태와 API 계약을, FastAPI는 문서 분석과 AI 처리를 담당하도록 분리했습니다.
- 2. 처리 상태 관리
장시간 분석을 비동기로 실행하고 PROCESSING · COMPLETED · FAILED 상태로 결과를 추적했습니다.
- 3. 답변 근거 보존
선택된 Chunk를 ChatReference로 저장해 새로고침 이후에도 답변 근거를 다시 조회할 수 있게 했습니다.
- 4. 실패 진단 구조
requestId, AiCallLog, 오류 코드와 응답 시간을 연결해 문서 실패와 AI 호출 실패를 구분했습니다.

02 구현하며 얻은 인사이트

- 1. RAG 품질
모델뿐 아니라 검색 범위, 후보 구성, 재정렬, 근거 저장에 함께 설계되어야 했습니다.
- 2. 비동기 처리
빠른 응답뿐 아니라 Thread Pool, DB Connection, 외부 API Rate Limit을 함께 측정해야 했습니다.
- 3. 부분 성공
일부 Vector가 저장된 상태의 실패에는 재시도뿐 아니라 보상 처리와 실패 상태가 필요했습니다.
- 4. 운영 로그
요청이 Rollback되더라도 실패 원인과 호출 시간은 별도로 남아야 했습니다.

03 구현 당시 선택을 다시 검토

- 1. Conversation Summary + Recent Window
한계: 독립 질문에도 과거 문맥이 개입할 수 있음
다음: Follow-up 판별과 Query Rewrite 비교
- 2. Batch 10 / Thread Pool Core 5 · Max 10 · Queue 50
한계: 부하 시험으로 도출한 설정값이 아님
다음: 동시 업로드 · DB Connection · Rate Limit 측정
- 3. Rule-based Reranker
한계: 설명 가능하지만 검색 품질의 상한이 존재
다음: 고정 평가셋으로 Cross-encoder · LLM Reranker 비교
- 4. Partial Vector Cleanup
한계: 완전한 원자적 교체 구조는 아님
다음: Staging Table · Job Version 기반 교체 검토

04 남은 한계와 성장 방향

- 1. 검색 평가 체계
정답 근거가 포함된 평가 질문을 만들고 Recall@K · MRR · nDCG@K · 근거 적합도를 측정할 필요가 있습니다.
- 2. 독립 작업 처리 구조
동시 업로드가 증가하면 API 요청과 문서 처리를 Queue·Worker 구조로 분리해야 합니다.
- 3. 원자적 Vector 교체
Cleanup 보상 방식에서 Staging·Version 기반 교체 구조를 검토할 필요가 있습니다.
- 4. 근거 정밀도
Chunk 단위 Reference를 문장·좌표 단위로 세분화해 PDF 원문과의 연결성을 높일 수 있습니다.

자연어로 상품을 탐색하고 행동까지 연결하는 AI 쇼핑 서비스

자연어 상품 탐색과 대화형 추천 결과를 장바구니·주문·반품 같은 핵심 기능으로 연결

기간	형태	역할
2025.10 ~ 2025.11	5인 팀 프로젝트	Elasticsearch 검색 랭킹 · Frontend State Management · Guest Cart 병합 · 인증 흐름 개선

GitHub <https://github.com/seochanjin/Accio>

기획 배경

키워드 중심 쇼핑 검색은 사용자가 원하는 분위기·용도·취향을 구체적으로 표현하기 어려움
자연어로 요구사항을 입력하고 대화를 이어가며 상품을 좁혀가는 쇼핑 경험 구현

문제 정의

AI 검색 결과와 대화 상태가 화면 이동·새로고침 이후 소실 → 탐색을 처음부터 반복
비회원 장바구니와 로그인 후 장바구니 분리
인증 갱신 실패가 사용자 흐름 중단

핵심 가설


검색 조건과 AI 대화 상태를 세션 단위로 복원
비회원 장바구니를 로그인 계정에 병합
→ 탐색부터 구매까지 사용자 흐름 유지 가능

목표

AI 검색 세션 복원 · 비회원 장바구니 병합 · Refresh Token 기반 인증 흐름 적용
화면 이동·새로고침·로그인 전환 이후에도 탐색과 구매 연속성 확보

기술 스택

Frontend	React · TypeScript
Backend	FastAPI
AI / Search	AWS Bedrock · Titan Embedding · Elasticsearch
Data	MongoDB · Redis
Infrastructure	AWS



메인 화면 · 자연어 상품 검색과 추천 결과

AI 검색 세션 복원

검색 조건과 대화 결과를 세션 단위로 저장

화면 이동·새로고침 이후 복원

Guest Cart 병합

로그인 시 비회원 장바구니 항목을 계정 장바구니로 병합

인증 흐름 개선

Access Token 만료 시 Refresh Token으로 갱신

갱신 실패 시 인증 상태 정리

키워드와 의미 검색을 결합한 상품 탐색 구조

기존 Elasticsearch 키워드 검색에 Titan V2 임베딩 기반 KNN 검색을 추가

01 사용자 자연어 질의

“집에서 편하게 입을 따뜻한 옷” · “4만원대 가성비 좋은 무선 이어폰”
상품명뿐 아니라 용도·취향·가격 조건을 포함한 입력



02 Query 준비

규칙 기반 정규화 · Titan V2 Query Embedding · 1024차원
Redis Query Cache · Claude Fallback



03 Elasticsearch 단일 Hybrid 요청

Keyword Query

multi_match · term · match_phrase fuzziness · field boost

정확한 상품명·브랜드·카테고리 검색

KNN Query

Titan V2 Embedding k=50 · num_candidates=150

표현이 달라도 의미가 가까운 상품 검색

query + knn을 하나의 Elasticsearch 요청으로 실행



04 점수와 정렬 정책

Keyword function_score — reviewCount · rating · 기존 상품 rank 반영

Relevance: _score desc → rank asc

Popular: reviewCount desc → _score desc → rank asc



05 상품 결과

정확한 키워드 조건과 자연어 의미 조건을 하나의 결과 목록으로 반환

결과 부족 시 재검색

조건: 첫 페이지 요청 · 1차 검색 총 결과 10건 미만

Catalog Query Expansion → 확장 Keyword 생성 → 2차 Keyword 검색 → 결과가 더 많을 때만 교체

01 배경

- 기존 상품 검색은 Elasticsearch 키워드 검색 사용
- "집에서 편하게 입을 옷", "감성적인 홈 인테리어"처럼 상품명과 일치하지 않는 자연어 의도 반영 필요

02 문제

- 키워드 검색 — 상품명·브랜드·카테고리에 유리하나 다른 표현의 취향·용도는 놓침
- Vector 검색만 사용 — 정확한 상품명·문자열 조건의 영향 약화
- 두 방식 병행 유지 판단

03 설계 판단

- 키워드 검색을 대체하지 않고 Titan V2 Query Embedding 기반 KNN 검색 추가
- Keyword Query와 KNN Query를 하나의 Elasticsearch 요청으로 전달
- 검색 점수와 서비스 정렬 정책으로 최종 목록 구성

04 실제 적용

- Keyword Query — multi_match · term · match_phrase · fuzziness · 필드별 Boost
- function_score에 reviewCount · rating · 기존 상품 rank 반영
- KNN Query — Titan V2 1024차원 Query Embedding
- 첫 페이지 1차 검색 10건 미만 시 카탈로그 기반 Query 확장 후 2차 Keyword 검색

05 한계와 다음 검증

- Keyword-only · Vector-only · Hybrid 비교용 고정 평가셋 미구성
- RRF는 기능 제약으로 제거 → Elasticsearch 8.x 기본 Hybrid 동작 사용, 버전·설정에 따라 점수 결합 결과 상이 가능
- 평가셋 구성 후 Recall@K · MRR · nDCG@K · Zero-result Rate 비교 필요
- Embedding 호출 시간과 전체 검색 응답 시간 측정 필요

로그인 전환 과정에서도 장바구니와 인증 상태를 유지한 Frontend 흐름

비회원 장바구니를 로그인 계정에 병합하고, Access Token 만료 시 Refresh Token으로 인증 상태를 복구

01 Guest Cart 저장

비로그인 사용자가 상품 추가 → localStorage · cart-storage
productId · quantity · selectedColor · selectedSize · 상품 Snapshot

로그인 전 구매 상태를 브라우저에 유지



02 로그인 성공

사용자 인증 완료 로컬 장바구니 존재 여부 확인 — cart-storage 존재 + 상품 항목 1개 이상

로그인 완료 후 장바구니 병합을 후속 처리



03 병합 Payload 변환

상품 식별·옵션 productId · quantity selectedColor · selectedSize

상품 Snapshot priceSnapshot · nameSnapshot imageSnapshot

Frontend 상태를 Backend Cart API 형식으로 변환



04 서버 장바구니 병합 PUT /api/cart

성공

서버 장바구니 병합 → localStorage 제거 → 동일 상태 재전송 방지

실패

오류 기록 → 로그인 상태는 유지

Cart 병합을 로그인 완료와 분리된 후속 작업으로 처리



05 인증 상태 복구

Access Token 만료·부재 → Refresh Token 확인 → Access Token 재발급 요청

성공: 로그인 상태 유지 · 실패: 로그아웃 처리

Backend에 존재하던 재발급 흐름을 Frontend 인증 상태와 연결

01 배경

- 비회원이 담은 로컬 장바구니와 로그인 계정 장바구니의 저장 위치 상이
- 로그인 전 탐색·구매 준비가 로그인 이후에도 이어지도록 상태 전환 필요

02 문제

- 로그인 후 서버 장바구니만 조회 → 비회원 상태에서 담은 상품 소실 가능
- Access Token 만료 시 Refresh Token이 남아 있어도 Frontend에 재발급 흐름 부재 → 인증 상태 유지 실패

03 설계 판단

- 비회원 장바구니는 localStorage 유지, 로그인 성공 시 Backend Cart API 형식으로 변환해 전달
- 병합 작업을 인증 완료 이후의 후속 처리로 분리 → 병합 실패가 로그인 성공을 막지 않도록
- Access Token 만료 시 Refresh Token으로 재발급 시도하도록 연결

04 실제 적용과 결과

- 상품 ID · 수량 · 옵션 · 상품 Snapshot을 병합 Payload로 구성해 서버 전달
- 병합 성공 후 localStorage의 Guest Cart 제거 → 동일 상태 재전송 방지
- Access Token 부재·만료 시 Refresh Token으로 재발급, 성공 시 로그인 상태 유지
- 병합 오류는 기록하되 로그인 흐름은 계속 진행

05 한계와 다음 개선

- 서버·로컬 동일 상품의 수량 합산 · 옵션 충돌 · 중복 요청 정책을 명시적 도메인 계약으로 미정의
- 병합 API 멍등성, Refresh Token 만료·재발급 실패, 네트워크 오류 시 상태 전환 통합 테스트 부족
- 재설계 시 병합 규칙을 별도 도메인 정책으로 분리
- 로그인 · 병합 성공 · 병합 실패 · 토큰 만료 시나리오를 E2E 테스트로 검증

ACCIO / 구현 회고와 성장 방향

01 빠른 통합 과정에서 드러난 문제

1. 상태 관리 복잡도 증가

AI Tool·장바구니·인증을 단기간에 통합하며 화면과 서버의 여러 상태를 함께 관리해야 했습니다.

2. 검색 품질 검증 부족

Keyword-only·Vector-only·Hybrid 검색을 동일한 평가셋으로 비교하지 못했습니다.

3. 책임 범위 불명확성

팀 Search Engine과 개인 기여를 Commit·PR·문서로 명확히 구분하지 못했습니다.

4. 구현 근거 부족

빠른 기능 통합에 비해 설계 판단과 테스트 결과를 충분히 남기지 못했습니다.

02 개인 기여에서 얻은 인사이트

1. 상태 전환

Guest Cart 병합에서는 저장 위치보다 전환 조건과 기준 상태가 중요했습니다.

2. 실패 격리

병합 실패가 로그인 성공까지 막지 않도록 후속 작업으로 분리했습니다.

3. 인증 복구

Access Token 만료와 Refresh Token 재발급을 하나의 인증 Lifecycle로 관리했습니다.

4. 상태 정리

병합 성공 후 로컬 상태를 제거해 동일한 장바구니 상태의 재전송을 막았습니다.

03 남은 한계와 다음 검증

1. Cart 병합 계약

수량 합산·옵션 충돌·중복 요청 정책을 명시적인 도메인 계약으로 남기지 못했습니다.

2. 역등성과 실패 복구

병합 요청을 재시도했을 때 동일한 결과가 보장되는지 검증하지 못했습니다.

3. 인증 시나리오

Refresh Token 만료·재발급 실패·네트워크 오류를 포함한 E2E 테스트가 부족했습니다.

4. 검색 품질 평가

Keyword-only·Vector-only·Hybrid 검색을 고정 평가셋으로 비교하지 못했습니다.

04 개인 고민과 성장 방향

1. 기능 구현과 Ownership

기능을 만드는 것과 내 판단·수정·검증 범위를 근거로 남기는 것은 별개의 문제였습니다.

2. AI 기능과 Backend 설계

AI 연결 자체보다 상태 전환·실패 처리·권한·데이터 계약 설계가 더 중요했습니다.

3. 기술 방향

이후에는 AI 기능을 안정적인 서비스 흐름으로 연결하는 AI Backend와 Platform 영역에 집중했습니다.

4. 후속 프로젝트 반영

NotebookLM과 NewsLab에서는 책임 분리·명시적 상태·실패 기록·운영 검증을 개발 과정에 포함했습니다.